

Classification Analysis of Drug Use Risk Based on Personality and Demographic Factors Using Machine Learning Algorithm

Project Ujian Akhir Semester Genap Mata Kuliah Data Mining 2025/2026
Andika Febrianto (24031554018)¹, Dian Rohmatul Islam (24031554047)², Afifah (24031554202)³

Kelas 2024A

Dosen Pengampu: Moh. Khoridatul Huda, S.Pd., M.Si., Ph.D.
Program Studi Sains Data, Universitas Negeri Surabaya

Abstrak: Analisis Klasifikasi ini bertujuan untuk memprediksi risiko konsumsi narkoba berdasarkan faktor kepribadian dan demografi menggunakan metode *machine learning*. Dataset yang digunakan adalah *Drug Consumption (Quantified)* dari UCI Machine Learning Repository dengan 1.885 observasi yang mencakup variabel demografi, *Big Five Personality Traits*, impulsiveness, dan sensation seeking. Tahapan analisis meliputi preprocessing data, exploratory data analysis (EDA), *Association Rule Mining*, serta klasifikasi menggunakan algoritma Logistic Regression, Decision Tree, dan Random Forest. Evaluasi model dilakukan menggunakan confusion matrix, accuracy, dan ROC-AUC. Hasil analisis menunjukkan bahwa faktor psikologis seperti impulsiveness dan sensation seeking memiliki hubungan terhadap risiko konsumsi narkoba. Selain itu, Logistic Regression menghasilkan performa terbaik dengan akurasi sebesar 86.74% dan AUC sebesar 0.93. Hasil ini menunjukkan bahwa *machine learning* efektif digunakan untuk mengklasifikasikan risiko konsumsi narkoba berdasarkan karakteristik psikologis dan demografi individu.

Kata kunci: *Machine Learning*, Klasifikasi Narkoba, Logistic Regression, Random Forest, Big Five Personality Traits.

I. Pendahuluan

1.1 Latar Belakang

Perkembangan teknologi dan penerapan *machine learning* dalam bidang kesehatan saat ini, mendorong berbagai kajian terkait prediksi risiko konsumsi narkoba berdasarkan faktor psikologis dan demografi. Penyalahgunaan narkoba merupakan permasalahan global yang berdampak pada kesehatan fisik, mental, dan kehidupan sosial individu. Beberapa kajian menunjukkan bahwa faktor kepribadian seperti *impulsiveness*, *sensation seeking*, dan *Big Five Personality Traits* memiliki hubungan signifikan terhadap perilaku konsumsi zat adiktif (Bari et al., 2026; Gardiner & Lawson, 2023).

Metode *machine learning* dinilai efektif untuk menganalisis pola data yang kompleks dan menghasilkan prediksi dengan akurasi yang tinggi dibandingkan metode konvensional (Unlu & Subasi,

2025). Beberapa kajian sebelumnya juga menunjukkan bahwa algoritma *machine learning* mampu digunakan untuk memprediksi perilaku konsumsi narkoba dan tingkat risiko penyalahgunaan zat adiktif secara optimal (Kim et al., 2025; Fojo et al., 2021; Ruberu et al., 2022).

Project analisis ini menggunakan *Drug Consumption (Quantified) Dataset* dari UCI Machine Learning Repository yang memuat data demografi dan karakteristik psikologis responden seperti *Big Five Personality Traits*, *impulsiveness*, dan *sensation seeking*. Kompleksitas data tersebut memerlukan metode klasifikasi yang mampu menangani variabel numerik dan kategorik secara efektif. Oleh karena itu, analisis ini menerapkan algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest* untuk mengklasifikasikan risiko konsumsi narkoba berdasarkan faktor kepribadian dan demografi individu. *Logistic Regression* diterapkan

karena efektif untuk klasifikasi data kategorik, *Decision Tree* mudah diinterpretasikan, sedangkan *Random Forest* memiliki performa yang optimal dalam meningkatkan akurasi prediksi pada data kompleks (Breiman, 2001).

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam analisis ini adalah:

1. Bagaimana karakteristik data konsumsi narkoba berdasarkan faktor kepribadian dan demografi pada *Drug Consumption (Quantified) Dataset*?
2. Bagaimana hubungan faktor kepribadian seperti *Big Five Personality Traits*, impulsiveness, dan sensation seeking terhadap risiko konsumsi narkoba?
3. Bagaimana performa algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest* dalam mengklasifikasikan risiko konsumsi narkoba?
4. Algoritma machine learning manakah yang memberikan performa klasifikasi terbaik berdasarkan nilai accuracy, precision, recall, F1-score, dan ROC-AUC?
5. Bagaimana penerapan machine learning dalam membantu identifikasi risiko konsumsi narkoba berdasarkan karakteristik psikologis dan demografi individu?

1.3 Tujuan

Tujuan analisis ini adalah sebagai berikut:


1. Menganalisis karakteristik data konsumsi narkoba berdasarkan faktor kepribadian dan demografi menggunakan *Drug Consumption (Quantified) Dataset*.
2. Mengidentifikasi hubungan antara faktor kepribadian, impulsiveness, sensation seeking, dan karakteristik demografi terhadap risiko konsumsi narkoba.
3. Membangun model klasifikasi risiko konsumsi narkoba menggunakan

algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest*.

4. Membandingkan performa ketiga algoritma machine learning berdasarkan metrik evaluasi accuracy, precision, recall, F1-score, dan ROC-AUC.
5. Menentukan algoritma terbaik dalam memprediksi risiko konsumsi narkoba berdasarkan karakteristik psikologis dan demografi individu.

II. Metodologi Analisis

2.1 Diagram Alur Analisis



Gambar 1. Alur Diagram Analisis

Tahapan analisis pada gambar 1, dimulai dari data understanding, preprocessing data, *exploratory data analysis* (EDA), *Association Rule Mining*, klasifikasi menggunakan algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest*, Evaluasi model menggunakan confusion matrix, accuracy, dan ROC-AUC, Feature Importance *Random Forest*, serta dilakukan perbandingan hasil akurasi keseluruhan model.

2.1 Deskripsi Dataset

Dataset pada project analisis ini menggambarkan karakteristik individu berdasarkan faktor kepribadian, demografi, serta perilaku konsumsi narkoba. Dataset yang digunakan adalah *Drug Consumption (Quantified) Dataset* yang diperoleh dari UCI Machine Learning Repository (<https://archive.ics.uci.edu/dataset/373/drug+consumption+quantified>) dengan total 1.885 observasi, di mana setiap observasi merepresentasikan satu responden dengan karakteristik psikologis dan sosial yang berbeda. Dataset ini banyak digunakan dalam kajian terkait analisis perilaku konsumsi zat adiktif dan prediksi risiko useran narkoba

menggunakan metode statistik maupun *machine learning* (Bari et al., 2026; Unlu & Subasi, 2025; Kim et al., 2025). Variable yang digunakan dalam analisis ini terdiri dari variabel demografi yaitu *age*, *gender*, *education*, *country*, dan *ethnicity*, serta variable psikologis yang meliputi *Big Five Personality Traits* yaitu *neuroticism* (Nscore), *extraversion* (Escore), *openness* (Oscore), *agreeableness* (Ascore), *conscientiousness* (Cscore), *impulsiveness* (Impulsive), dan *sensation seeking* (SS). Selain itu, dataset juga memuat informasi konsumsi berbagai jenis narkoba yang digunakan sebagai variabel target klasifikasi untuk menentukan kategori user dan non-user narkoba. Beberapa kajian menunjukkan bahwa faktor kepribadian seperti *impulsiveness*, *sensation seeking*, dan karakteristik psikologis lainnya memiliki hubungan terhadap perilaku useran zat adiktif (Gardiner & Lawson, 2023; Maharjan et al., 2025). Dataset ini digunakan untuk menganalisis hubungan faktor kepribadian dan demografi terhadap risiko konsumsi narkoba menggunakan algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest* seperti yang ditunjukkan pada Tabel 1 yang berisi daftar variabel analisis.

Tabel 1. Variable Analysis

Simbol	Nama Variable	Keterangan
Y	Drug Consumption Risk	Kategori risiko konsumsi narkoba (User dan Non-User)
X1	Age	Kelompok usia responden
X2	Gender	Jenis kelamin responden
X3	Education	Tingkat pendidikan responden
X4	Country	Negara asal responden
X5	Ethnicity	Etnis responden
X6	Nscore	Tingkat Neuroticism
X7	Escore	Tingkat Extraversion
X8	Oscore	Tingkat Openness to Experience
X9	Ascore	Tingkat Agreeableness
X10	Cscore	Tingkat Conscientiousness
X11	Impulsive	Tingkat impulsiveness
X12	SS	Tingkat sensation seeking

2.2 Data Mining

Data mining merupakan proses penggalian informasi dan pola dari kumpulan data menggunakan metode statistik dan *machine learning* untuk melakukan proses prediksi dan pengambilan keputusan (Han et al., 2012). Dalam analisis ini, *data mining* digunakan untuk menganalisis hubungan faktor kepribadian dan demografi terhadap risiko konsumsi narkoba. Metode *data mining* yang digunakan meliputi klasifikasi dan *Association Rule Mining*. Proses klasifikasi dilakukan menggunakan algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest* untuk memprediksi kategori user dan non-user narkoba. Selain itu, *Association Rule Mining* digunakan untuk menemukan pola keterkaitan antar jenis konsumsi narkoba berdasarkan nilai *support*, *confidence*, dan *lift* (Han et al., 2012). Tahapan data mining pada analisis ini meliputi *data preprocessing*, *exploratory data analysis* (EDA), pembentukan aturan asosiasi, pembangunan model klasifikasi, serta evaluasi model menggunakan *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*. (Unlu & Subasi, 2025; Bari et al., 2026).

2.3 Machine Learning

Machine Learning merupakan salah satu cabang dari *data mining* dan kecerdasan buatan (*artificial intelligence*) yang digunakan untuk membangun model prediksi berdasarkan pola data (Han et al., 2012). Metode ini mampu menganalisis hubungan kompleks antarvariabel dan menghasilkan model prediksi dengan tingkat akurasi yang tinggi pada berbagai bidang, termasuk analisis perilaku konsumsi narkoba (Unlu & Subasi, 2025). Dalam analisis ini, *machine learning* digunakan untuk mengklasifikasikan risiko konsumsi narkoba berdasarkan faktor kepribadian dan demografi individu. Algoritma yang digunakan yaitu *Logistic Regression*,

Decision Tree, dan *Random Forest*. Ketiga algoritma tersebut diterapkan karena memiliki kemampuan yang optimal dalam proses klasifikasi data serta banyak digunakan dalam analisis prediksi perilaku konsumsi zat adiktif (Bari et al., 2026; Kim et al., 2025).

2.4 Association Rule Mining

Association Rule Mining merupakan metode *data mining* yang digunakan untuk menemukan pola hubungan antaritem dalam dataset berdasarkan nilai *support*, *confidence*, dan *lift*, dimana Nilai *lift* > 1 menunjukkan adanya hubungan positif antaritem. (Han et al., 2012). Pada project analisis ini, metode ini digunakan untuk menganalisis pola keterkaitan konsumsi antar jenis narkoba pada responden, menggunakan rumus yang dipaparkan pada gambar 2.

$$\text{Support (A, B)} = P(A \cap B) \dots\dots\dots(1)$$

$$\text{Support (A, B)} = \frac{\sum \text{Transaksi mengandung A dan B}}{\sum \text{Transaksi}} \dots\dots(2)$$

$$\text{Confidence} = P(B | A) \dots\dots\dots(3)$$

$$\text{Confidence} = \frac{\sum \text{Transaksi mengandung A dan B}}{\sum \text{Transaksi mengandung A}} \dots\dots\dots(4)$$

$$\text{Lift ratio} = \frac{\text{Confidence (A,B)}}{\text{Benchmark Confidence (A,B)}} \dots\dots\dots(5)$$

$$\text{Benchmark Confidence} = \frac{Nc}{N} \dots\dots\dots(6)$$

Gambar 2. Rumus Ukuran Association Rule Mining. Sumber:

<https://media.neliti.com/media/publications/554153-penerapan-metode-association-rule-untuk-45f642a0.pdf>

2.5 Logistic Regression

Logistic Regression merupakan algoritma klasifikasi yang digunakan untuk memprediksi probabilitas suatu data ke dalam kelas tertentu berdasarkan variabel prediktor. Metode ini efektif digunakan pada klasifikasi data kategorik dan banyak diterapkan dalam analisis prediksi perilaku konsumsi narkoba (Unlu & Subasi, 2025). Pada analisis ini, *Logistic Regression* digunakan untuk mengklasifikasikan kategori user dan non-user narkoba berdasarkan faktor kepribadian dan demografi individu. Model *Logistic Regression* dinyatakan dengan persamaan pada gambar 3.

$$f(x) = \frac{1}{1 + e^{-x}}$$

Gambar 3. Persamaan Logistic Regression.

Sumber: <https://aws.amazon.com/id/what-is/logistic-regression/>

2.6 Decision Tree

Decision Tree merupakan algoritma klasifikasi berbentuk struktur pohon yang digunakan untuk mengelompokkan data berdasarkan aturan tertentu. Metode ini bekerja dengan membagi data ke dalam beberapa cabang berdasarkan nilai variabel prediktor hingga menghasilkan kelas akhir. *Decision Tree* memiliki keunggulan karena mudah dipahami dan diinterpretasikan. Pada analisis ini, *Decision Tree* digunakan untuk mengklasifikasikan risiko konsumsi narkoba berdasarkan faktor kepribadian dan demografi individu. Proses pembentukan pohon dilakukan menggunakan perhitungan *Entropy* dan *Information Gain* seperti pada gambar 4.

$$\text{Entropy (S)} = \sum_{i=1}^n - p_i * \log_2 p_i$$

$$\text{Gain (S,A)} = \text{Entropy (S)} - \sum_{i=1}^n * \text{Entropy (Si)}$$

Gambar 4. Perhitungan Entropy dan Information Gain Decision Tree. Sumber:

<https://sis.binus.ac.id/2022/01/21/decision-tree-algoritma-beserta-contohnya-pada-data-mining/>

2.7 Random Forest

Random Forest merupakan algoritma *ensemble learning* yang bekerja dengan membangun banyak *Decision Tree* dan menggabungkan hasil prediksi dari setiap pohon untuk meningkatkan akurasi klasifikasi (Breiman, 2001). Metode ini mampu menangani data kompleks, mengurangi *overfitting*, serta menghasilkan performa prediksi yang lebih stabil dibandingkan *Decision Tree* tunggal. Pada proses klasifikasi, prediksi akhir ditentukan berdasarkan mayoritas hasil prediksi dari seluruh pohon keputusan, yang dirumuskan pada gambar 5.

$$mr(X, Y) = P_{\theta}(h(X, \theta) = Y) - \max_{j \neq Y} P_{\theta}(h(X, \theta) = j)$$

Gambar 5. rumus prediksi akhir pada algoritma Random Forest. *Sumber:*
<https://share.google/iwDYrLBxRYcxg9T5b>

2.8 Evaluasi Model

Evaluasi model dilakukan untuk mengukur performa algoritma klasifikasi dalam memprediksi risiko konsumsi narkoba menggunakan *confusion matrix*, *accuracy*, *precision*, *recall*, *F1-score*, dan ROC-AUC. *Confusion matrix* digunakan untuk melihat jumlah prediksi benar dan salah yang dihasilkan model, sedangkan *accuracy* digunakan untuk mengukur tingkat ketepatan klasifikasi. *Precision* menunjukkan ketepatan prediksi pada kelas positif, *recall* mengukur kemampuan model dalam mendeteksi kelas positif, dan *F1-score* digunakan untuk menyeimbangkan nilai *precision* dan *recall*. Selain itu, ROC-AUC digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas user dan non-user narkoba. Evaluasi ini digunakan untuk membandingkan performa algoritma *Logistic Regression*, *Decision Tree*, dan *Random Forest* dalam menghasilkan model klasifikasi terbaik.

III. Hasil dan Pembahasan

3.1 Karakteristik Dataset

Tabel 2. Statistika Deskriptif

Variable	Mean	Std	Min	Q1	Med	Q3	Max
Age	0.03	0.87	-0.95	-0.95	-0.07	0.49	2.59
Gender	-0.00	0.48	0.48	0.48	-0.48	0.48	0.48
Edu	-0.00	0.95	2.43	0.61	-0.05	0.45	1.98
Country	0.35	0.70	0.57	0.57	0.96	0.96	0.96
Ethnicity	-0.30	0.16	1.10	0.31	-0.31	0.31	1.90
Nscore	0.00	0.99	3.46	0.67	0.04	0.62	3.27
Escore	-0.00	0.99	3.27	0.69	0.00	0.63	3.27
Oscore	-0.00	0.99	3.27	0.71	-0.01	0.72	2.90
Ascore	-0.00	0.99	-	-	-0.01	0.76	3.46

Variable	Mean	Std	Min	Q1	Med	Q3	Max
			3.46	0.60			
Cscore	-0.00	0.99	3.46	0.65	-0.00	0.58	3.46
Impulsive	0.00	0.95	2.55	0.71	-0.21	0.52	2.90
SS	-0.00	0.96	2.07	0.52	0.07	0.76	1.92

Berdasarkan hasil statistika deskriptif pada Tabel 2, diperoleh gambaran umum mengenai karakteristik variabel pada dataset *Drug Consumption (Quantified)*. Variabel pada dataset terdiri dari faktor demografi dan faktor psikologis seperti *Big Five Personality Traits*, *impulsiveness*, dan *sensation seeking*. Nilai rata-rata (*mean*) pada sebagian besar variabel berada di sekitar nol, sedangkan standar deviasi (*std*) berkisar antara 0.16 hingga 0.99. Hal tersebut menunjukkan bahwa distribusi data antar variabel relatif seimbang meskipun memiliki tingkat penyebaran yang berbeda. Nilai median pada sebagian besar variabel juga berada di sekitar nol, seperti pada variabel *Nscore*, *Escore*, *Oscore*, *Ascore*, dan *Cscore*. Hal ini menunjukkan bahwa sebagian besar observasi terkonsentrasi di sekitar nilai tengah distribusi. Variabel *Impulsive* memiliki median sebesar -0.21, sedangkan variabel *SS (Sensation Seeking)* memiliki median sebesar 0.07 yang menunjukkan adanya variasi tingkat impulsivitas dan kecenderungan pencarian sensasi pada responden. Rentang nilai minimum dan maksimum pada beberapa variabel menunjukkan adanya variasi data yang cukup besar. Variabel *Nscore*, *Ascore*, dan *Cscore* memiliki rentang nilai dari -3.46 hingga 3.46, sedangkan variabel *Escore* dan *Oscore* memiliki nilai maksimum lebih dari 2.90. Hal ini menunjukkan bahwa karakteristik kepribadian responden cukup beragam dan terdapat beberapa observasi dengan nilai ekstrem. Pada variabel demografi, *Age* memiliki rentang nilai dari -0.95 hingga 2.59 dengan standar deviasi sebesar 0.87 yang menunjukkan variasi usia responden

yang cukup beragam. Variabel *Country* memiliki median dan kuartil atas sebesar 0.96, sedangkan *Ethnicity* memiliki penyebaran data yang relatif lebih kecil dibandingkan variabel lainnya. Secara keseluruhan, hasil statistika deskriptif menunjukkan bahwa dataset memiliki distribusi data yang cukup bervariasi dan dapat digunakan untuk analisis klasifikasi risiko konsumsi narkoba menggunakan metode *machine learning*.

3.2 Preprocessing

Preprocessing data dilakukan untuk meningkatkan kualitas data sebelum proses klasifikasi. Berdasarkan tabel 3 dan 4, hasil pengecekan *missing value* dan data duplikat, seluruh variabel memiliki nilai 0 sehingga dataset tidak memiliki data hilang maupun data ganda.

Tabel 3. Total Duplikasi Data

Total
np.int64(0)

Tabel 4. Total Missing Values

Variable	Total
Age	0
Gender	0
Education	0
Country	0
Ethnicity	0
...	...
Meth	0
Mushrooms	0
Nocotine	0
Semer	0
Vsa	0

Selanjutnya dilakukan transformasi variabel target *cannabis* menjadi klasifikasi biner, yaitu user (1) dan non-user (0), seperti yang terdapat pada tabel 5. Hasil transformasi menunjukkan terdapat 999 data user dan 886 data non-user sehingga distribusi kelas relatif seimbang. Proses ini dilakukan agar algoritma klasifikasi dapat memprediksi kategori risiko konsumsi narkoba secara lebih efektif (Han et al., 2012).

Tabel 5. Hasil Transformasi Target


Cannabis	
Kelas	Total

1	999
0	886

Pada proses encoding, variabel kategorik diubah menjadi bentuk numerik menggunakan *Label Encoding* agar dapat diproses oleh algoritma machine learning. Setelah itu, data dipisahkan menjadi variabel fitur (*X*) dan variabel target (*y*). Variabel fitur terdiri dari faktor demografi dan psikologis seperti *Big Five Personality Traits*, *impulsiveness*, dan *sensation seeking* yang diketahui memiliki hubungan terhadap perilaku konsumsi zat adiktif (Bari et al., 2026; Gardiner & Lawson, 2023). Selanjutnya, dilakukan standarisasi data menggunakan *StandardScaler* untuk menyamakan skala antar variabel sehingga proses pembentukan model menjadi lebih stabil dan optimal, terutama pada algoritma Logistic Regression (Pedregosa et al., 2011). Setelah itu, data dibagi menjadi data *training* sebesar 80% dan data *testing* sebesar 20% menggunakan *train-test split* dengan *stratify* agar proporsi kelas target tetap seimbang pada kedua kelompok data (Unlu & Subasi, 2025).

3.3 Exploratory Data Analysis (EDA)

3.3.1 Distribusi Data




Gambar 6. Distribusi Data User dan Non-User

Berdasarkan Gambar 6, jumlah data user *cannabis* (class 1) lebih banyak dibandingkan non-user (class 0), yaitu sebanyak 999 dan 886 observasi. Hasil ini menunjukkan bahwa distribusi kelas pada dataset relatif seimbang sehingga risiko *class imbalance* cukup rendah. Distribusi data yang seimbang merupakan hal krusial dalam proses *machine learning*, karena dapat

membantu model menghasilkan performa klasifikasi yang lebih stabil dan mengurangi bias terhadap kelas tertentu (Unlu & Subasi, 2025).


3.3.2 Korelasi Antar Fitur



Gambar 7. Heatmap Korelasi Antar Fitur

Berdasarkan heatmap korelasi antar fitur pada gambar 7, beberapa variabel memiliki hubungan cukup kuat terhadap variabel target *cannabis*. Variabel *legalh* dan *nicotine* memiliki korelasi positif tertinggi sebesar 0.52, *ecstasy* (0.48), *mushrooms* (0.47), dan *sensation seeking* (ss) sebesar 0.44. Hal ini menunjukkan bahwa faktor perilaku useran zat lain dan karakteristik psikologis berhubungan dengan risiko konsumsi *cannabis*. Selain itu, variabel *age* (-0.45) dan *country* (-0.54) menunjukkan korelasi negatif terhadap variabel target. Secara umum, tidak terdapat korelasi yang sangat tinggi antar fitur, sehingga risiko multikolinearitas relatif rendah.

3.3.3 Distribusi Personality Traits




Gambar 8. Histogram Distribusi Personality Traits

Berdasarkan histogram pada gambar 8, distribusi variabel *personality traits* seperti *nscore*, *escore*, *oscore*, *ascore*, dan *cscore* cenderung membentuk pola mendekati distribusi normal dengan pusat data berada di sekitar nilai 0.

Sebagian besar responden memiliki nilai kepribadian pada kategori sedang, sedangkan hanya sedikit observasi yang berada pada nilai ekstrem. Variabel *cscore* dan *ascore* menunjukkan distribusi yang lebih terkonsentrasi di sekitar pusat data, sedangkan *nscore* dan *oscore* memiliki penyebaran yang lebih lebar. Hasil ini menunjukkan bahwa karakteristik kepribadian responden cukup beragam dan dapat digunakan sebagai fitur dalam proses klasifikasi risiko konsumsi narkoba.

3.3.4 Analisis Boxplot Personality Traits



Gambar 9. Boxplot Personality Traits

Berdasarkan boxplot pada gambar 9, seluruh variabel *personality traits* memiliki median yang berada di sekitar nilai 0 dengan sebaran data yang relatif simetris. Variabel *oscore* dan *ascore* menunjukkan rentang interkuartil yang lebih lebar dibandingkan variabel lainnya, sehingga memiliki variasi data yang lebih tinggi. Selain itu, terlihat beberapa *outlier* pada seluruh variabel, baik pada nilai rendah maupun tinggi, yang menunjukkan adanya responden dengan karakteristik kepribadian yang sangat berbeda dari mayoritas data.

3.4 Association Rule Mining

Association Rule Mining dilakukan untuk mengetahui pola keterkaitan konsumsi beberapa jenis narkoba pada dataset. Proses diawali dengan transformasi data ke bentuk biner menggunakan variabel alkohol, cannabis, coke, ecstasy, dan heroin, di mana nilai 1 menunjukkan user dan 0 menunjukkan non-user. Proses ini diperlukan agar data

dapat diproses menggunakan algoritma Apriori dalam menemukan frequent itemsets dan aturan asosiasi (Han et al., 2012).

Tabel 6. Hasil Apriori

Support	Itemsets
0.927851	Alcohol
0.529973	Cannabis
0.221220	Coke
0.274271	Ecstasy
0.062599	Heroin

Hasil Apriori pada tabel 6, menunjukkan bahwa alcohol memiliki nilai support tertinggi sebesar 0.927, diikuti cannabis sebesar 0.530 dan ecstasy sebesar 0.274. Hal ini menunjukkan bahwa konsumsi alcohol dan cannabis merupakan pola useran zat yang paling sering muncul pada dataset.

Tabel 7. Hasil Association Rules

Antecedents	Cons	Sup	Conf	Lift
Cannabis	Alcohol	0.50	0.94	1.02
Coke	Alcohol	0.21	0.98	1.06
Ecstasy	Alcohol	0.26	0.97	1.04
...	...	...	...	...
Canna, Coke	Ecs, Alco	0.14	0.72	2.70
Coke, Alcohol	Canna, Ecs	0.14	0.65	2.58
Coke, Ecstasy	Canna, Alco	0.14	0.89	1.78
Coke	Can, Alc, Ecs	0.14	0.64	2.62

Berdasarkan hasil association rules pada Tabel 7, diperoleh beberapa pola keterkaitan konsumsi zat adiktif dengan nilai confidence dan lift yang cukup tinggi. Aturan (*Cannabis*) dan (*Alcohol*) memiliki confidence sebesar 0.94, yang menunjukkan bahwa sebagian besar user cannabis juga mengonsumsi alcohol. Selain itu, aturan (*Coke*) dan (*Alcohol*) serta (*Ecstasy*) dan (*Alcohol*) memiliki confidence masing-masing sebesar 0.98 dan 0.97, sehingga menunjukkan bahwa alcohol sering muncul bersamaan dengan useran zat lain. Pada kombinasi beberapa zat, aturan (*Canna, Coke*) dan (*Ecs, Alco*) memiliki nilai lift tertinggi sebesar 2.70, yang menunjukkan adanya hubungan asosiasi yang kuat antara cannabis, coke, ecstasy, dan alcohol. Nilai lift di atas 1 pada seluruh aturan menunjukkan

adanya hubungan positif antar konsumsi zat adiktif. Hasil ini menunjukkan bahwa perilaku useran narkoba pada dataset memiliki pola konsumsi yang saling berkaitan (Han et al., 2012).

3.5 Hasil Klasifikasi Prediksi Model

3.5.1 Logistic Regression

Tabel 8. Hasil Prediksi Logistic Regression

Model	Hasil
Logistic Regression	1 1 0 1 1 0 1 1 1 1 1 1 0 0 0 0 1 1 0 1

Hasil prediksi menggunakan algoritma *Logistic Regression* pada tabel 8 menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data ke dalam kategori user (1) dan non-user (0) narkoba secara konsisten. Berdasarkan 20 data prediksi pertama, model menghasilkan dominasi kelas user, yang menunjukkan bahwa *Logistic Regression* dapat menangkap pola hubungan antara faktor kepribadian dan demografi terhadap risiko konsumsi narkoba (Han et al., 2012).

3.5.2 Decision Tree

Tabel 9. Hasil Prediksi Decision Tree

Model	Hasil
Decision Tree	1 1 0 1 0 0 1 0 1 1 1 1 0 0 0 0 1 1 0 1

Model *Decision Tree* menghasilkan prediksi yang cukup optimal dalam membedakan kategori user dan non-user narkoba. Namun, dibandingkan *Logistic Regression* dan *Random Forest*, terlihat terdapat beberapa perbedaan hasil prediksi pada beberapa observasi yang ditunjukkan oleh tabel 9. Hal ini menunjukkan bahwa *Decision Tree* lebih sensitif terhadap pola data tertentu karena proses klasifikasi dilakukan berdasarkan pembentukan aturan pohon keputusan.

3.5.3 Random Forest

Tabel 10. Hasil Prediksi Random Forest

Model	Hasil
Random Forest	1 1 0 1 1 0 1 1 1 1 1 1 0 0 0 0 1 1 0 1

Hasil prediksi *Random Forest* pada tabel 10 menunjukkan pola klasifikasi yang sangat stabil dan konsisten. Berdasarkan 20 data prediksi pertama, hasil klasifikasi *Random Forest* serupa dengan *Logistic Regression*. Algoritma ini bekerja dengan menggabungkan banyak pohon keputusan sehingga mampu mengurangi overfitting dan meningkatkan stabilitas model (Breiman, 2001). Berdasarkan hasil prediksi ketiga model, *Logistic Regression* dan *Random Forest* menghasilkan pola klasifikasi yang sama pada 20 data pertama, sedangkan *Decision Tree* menunjukkan beberapa perbedaan prediksi. Hal ini menunjukkan bahwa *Random Forest* dan *Logistic Regression* memiliki konsistensi klasifikasi yang lebih optimal pada dataset ini. Secara umum, ketiga model mampu digunakan untuk memprediksi risiko konsumsi narkoba berdasarkan faktor kepribadian dan demografi individu (Breiman, 2001).


3.6 Evaluasi Model

3.6.1 Logistic Regression

Tabel 11. Hasil Accuracy Logistic Regression


Accuracy
0.8673740053050398

Berdasarkan hasil evaluasi pada tabel 11, model *Logistic Regression* memperoleh nilai accuracy sebesar 0.8673 atau 86.73%. Hasil ini menunjukkan bahwa model mampu mengklasifikasikan data user dan non-user narkoba dengan optimal berdasarkan faktor kepribadian dan demografi. Hasil tersebut menyatakan bahwa algoritma *machine learning* efektif digunakan untuk prediksi perilaku konsumsi zat adiktif (Unlu & Subasi, 2025).



Gambar 10. Confusion Matrix Logistic Regression

Berdasarkan confusion matrix pada model *Logistic Regression* pada gambar 10, diperoleh sebanyak 152 data berhasil diklasifikasikan dengan benar sebagai non-user (*true negative*) dan 175 data berhasil diklasifikasikan dengan benar sebagai user (*true positive*). Selain itu, terdapat 25 data non-user yang salah diprediksi sebagai user (*false positive*) dan 25 data user yang salah diprediksi sebagai non-user (*false negative*). Hasil ini menunjukkan bahwa *Logistic Regression* memiliki performa klasifikasi yang optimal dan relatif seimbang dalam memprediksi kedua kelas (Unlu & Subasi, 2025).



Gambar 11. ROC-AUC Logistic Regression

Berdasarkan hasil ROC Curve dan nilai Area Under Curve (AUC) pada gambar 11. Model *Logistic Regression* memperoleh nilai AUC sebesar 0.93, yang menunjukkan kemampuan klasifikasi sangat optimal karena kurva ROC mendekati sudut kiri atas. Hasil ini menunjukkan bahwa *Logistic Regression* mampu menghasilkan pemisahan kelas yang optimal pada berbagai threshold prediksi. Selain itu, model ini juga memiliki performa akurasi tertinggi dibandingkan model lainnya sehingga dinilai cukup stabil dalam melakukan klasifikasi data konsumsi narkoba (Unlu & Subasi, 2025).


3.6.2 Decision Tree

Tabel 12. Hasil Accuracy Decision Tree

Accuracy
0.8116710875331565


Berdasarkan hasil evaluasi pada tabel 12, model *Decision Tree* memperoleh nilai accuracy sebesar 0.8116 atau 81.16%. Hasil ini menunjukkan bahwa model mampu mengklasifikasikan data

user dan non-user narkoba dengan cukup optimal.



Gambar 12. Confusion Matrix Decision Tree

Berdasarkan confusion matrix pada model *Decision Tree* pada gambar 12, diperoleh sebanyak 133 data berhasil diklasifikasikan dengan benar sebagai non-user (*true negative*) dan 173 data berhasil diklasifikasikan dengan benar sebagai user (*true positive*). Selain itu, terdapat 44 data non-user yang salah diprediksi sebagai user (*false positive*) dan 27 data user yang salah diprediksi sebagai non-user (*false negative*). Hasil ini menunjukkan bahwa model memiliki kemampuan yang cukup optimal dalam membedakan kategori user dan non-user narkoba (Han et al., 2012).



Gambar 13. ROC-AUC Decision Tree

Berdasarkan gambar 13, model *Decision Tree* memperoleh nilai AUC sebesar 0.89. Nilai tersebut masih termasuk kategori optimal, tetapi performanya sedikit lebih rendah dibandingkan *Logistic Regression*. Kurva ROC pada *Decision Tree* menunjukkan bahwa model masih mampu membedakan dua kelas dengan cukup optimal, meskipun cenderung lebih sensitif terhadap pola *data training* sehingga berpotensi mengalami *overfitting* pada data kompleks.


3.6.3 Random Forest

Tabel 13. Hasil Accuracy Random Forest

Accuracy


0.8594164456233422

Berdasarkan hasil evaluasi pada tabel 13, model *Random Forest* memperoleh nilai accuracy sebesar 0.8594 atau 85.94%. Hasil ini menunjukkan bahwa *Random Forest* mampu mengklasifikasikan data user dan non-user narkoba dengan optimal. Algoritma ini memiliki performa yang stabil karena menggunakan kombinasi banyak pohon keputusan sehingga mampu meningkatkan akurasi prediksi dan mengurangi *overfitting* (Breiman, 2001).



Gambar 14. Confusion Matrix Random Forest


Berdasarkan confusion matrix pada model *Random Forest* pada gambar 14, diperoleh sebanyak 145 data berhasil diklasifikasikan dengan benar sebagai non-user (*true negative*) dan 179 data berhasil diklasifikasikan dengan benar sebagai user (*true positive*). Selain itu, terdapat 32 data non-user yang salah diprediksi sebagai user (*false positive*) dan 21 data user yang salah diprediksi sebagai non-user (*false negative*). Hasil ini menunjukkan bahwa *Random Forest* memiliki performa klasifikasi yang optimal dengan kemampuan prediksi user yang cukup tinggi. Penggunaan banyak pohon keputusan pada *Random Forest* mampu meningkatkan stabilitas model dan mengurangi kesalahan prediksi dibandingkan *single decision tree* (Breiman, 2001).



Gambar 15. ROC-AUC Random Forest

Berdasarkan gambar 15, model *Random Forest* memperoleh nilai AUC sebesar 0.93 yang serupa dengan *Logistic Regression*. Hasil tersebut menunjukkan bahwa *Random Forest* memiliki kemampuan klasifikasi yang sangat optimal dalam memprediksi risiko konsumsi cannabis. Kombinasi banyak pohon keputusan pada *Random Forest* mampu meningkatkan stabilitas model dan mengurangi risiko *overfitting* dibandingkan *Decision Tree* tunggal (Breiman, 2001; Bari et al., 2026; Kim et al., 2025).

3.7 Feature Importance Random Forest



Gambar 16. Feature Importance Random Forest

Berdasarkan hasil feature importance Random Forest pada gambar 16, variabel *country*, *legalh*, *nicotine*, dan *ecstasy* memiliki kontribusi terbesar dalam proses klasifikasi konsumsi *cannabis*. Selain itu, faktor psikologis seperti *sensation seeking* (ss), *openness* (oscore), dan *neuroticism* (nscore) juga menunjukkan pengaruh yang cukup penting terhadap prediksi model. Sedangkan, variabel seperti *caff*, *crack*, dan *semer* memiliki nilai *importance* yang rendah sehingga kontribusinya terhadap model relatif kecil. *Random Forest* mampu mengidentifikasi variabel penting secara efektif melalui kombinasi banyak pohon keputusan sehingga menghasilkan model klasifikasi yang stabil pada data kompleks (Breiman, 2001).

3.8 Perbandingan dan Model Terbaik



Gambar 17. Perbandingan Seluruh Model

Berdasarkan hasil evaluasi pada gambar 17, model *Logistic Regression* menghasilkan performa terbaik dengan akurasi sebesar 86.74% dan nilai AUC sebesar 0.93, dan *Random Forest* dengan akurasi 85.94%, sedangkan *Decision Tree* memperoleh akurasi terendah sebesar 81.17%. Hasil tersebut menunjukkan bahwa *Logistic Regression* lebih optimal dalam mengklasifikasikan risiko konsumsi cannabis pada dataset yang digunakan, sedangkan *Random Forest* tetap menunjukkan performa yang stabil dalam menangani data kompleks melalui kombinasi banyak pohon keputusan (Breiman, 200; Bari et al., 2026; Unlu & Subasi, 2025).

Bab 4. Kesimpulan dan Saran

Berdasarkan hasil analisis, faktor psikologis dan demografi seperti *sensation seeking*, *neuroticism*, *country*, serta konsumsi zat lain berpengaruh terhadap risiko konsumsi *cannabis*. Hasil klasifikasi menunjukkan bahwa *Logistic Regression* menjadi model terbaik dengan akurasi 86,73% dan AUC 0,93, *Random Forest* dengan akurasi 85,94%, sedangkan *Decision Tree* memperoleh akurasi 81,17%. Selain itu, *Association Rule Mining* menunjukkan adanya hubungan kuat antara konsumsi *cannabis*, *alcohol*, *coke*, dan *ecstasy*. Namun, analisis ini memiliki keterbatasan karena jumlah data relatif terbatas, hanya menggunakan satu dataset, serta belum menerapkan *hyperparameter tuning* sehingga performa model masih dapat ditingkatkan (Breiman, 2001; Unlu & Subasi, 2025). Saran untuk analisis selanjutnya adalah menggunakan dataset yang lebih besar dan beragam, menambahkan variabel psikologis maupun sosial lainnya, serta menerapkan teknik *hyperparameter tuning* atau algoritma yang lebih kompleks untuk meningkatkan performa prediksi.

Daftar Pustaka

- Bari, S., Vike, N. L., Kim, B. W., Block, M., Stefanopoulos, L., Katsaggelos, A. K., & Breiter, H. C. (2026). Predicting substance use behaviors with machine learning using small sets of judgment and contextual variables. *NPJ Mental Health Research*, 5(1), 5.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32.
- Fojo, A. T., Lesko, C. R., Benke, K. S., Chander, G., Lau, B., Moore, R. D., Zandi, P. P., & Zeger, S. L. (2021). A learning algorithm for predicting mental health symptoms and substance use. *Journal of Psychiatric Research*, 134, 22–29.
- Gardiner, J. D., & Lawson, J. (2023). Depending on the Dark Triad: Exploring relationships between malign personality traits, substance and process addictions. *Journal of Substance Use*, 28(2), 243–248.
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Elsevier.
- Islam, U. I., et al. (2021). *Predicting individual substance abuse vulnerability using machine learning techniques* (arXiv Preprint No. arXiv:2101.03184). arXiv.
- Kim, S.-Y., Park, T., Kim, K., Oh, J., Park, Y., & Kim, D.-J. (2021). A deep learning algorithm to predict hazardous drinkers and the severity of alcohol-related problems using K-HANES. *Frontiers in Psychiatry*, 12, 684406.
- Kim, S., Kim, H., Kim, S., Lee, H., Hammoodi, A., Choi, Y., Kim, H., Smith, L., Kim, M., Fond, G., Boyer, L., Baik, S., Lee, H., Park, J., Kwon, R., Woo, S., & Yon, D. (2025). Machine learning-based prediction of substance use in adolescents in three independent worldwide cohorts: Algorithm development and validation study. *Journal of Medical Internet Research*, 27, e62805.
- Maharjan, J., Jin, R., Zhu, J., & Kenne, D. (2025). Intersection of Big Five personality traits and substance use on social media discourse: AI-powered observational study. *Journal of Medical Internet Research*, 27, e79454.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Ramos, L. A., Blankers, M., van Wingen, G., de Bruijn, T., Pauws, S. C., & Goudriaan, A. E. (2021). Predicting success of a digital self-help intervention for alcohol and substance use with machine learning. *Frontiers in Psychology*, 12, 734633.
- Ruberu, T. L. M., Kenyon, E. A., Hudson, K. A., Filbey, F., Ewing, S. W. F., Biswas, S., & Choudhary, P. K. (2022). Joint risk prediction for hazardous use of alcohol, cannabis, and tobacco among adolescents: A preliminary study using statistical and machine learning. *Preventive Medicine Reports*, 25, 101674.
- Sze, W. Y. S., et al. (2024). *Personality trait inference via mobile phone sensors: A machine learning approach* (arXiv Preprint No. arXiv:2401.10305). arXiv.
- Unlu, A., & Subasi, A. (2025). Substance use prediction using artificial intelligence techniques. *Journal of Computational Social Science*, 8, 21.
- Wang, T., et al. (2025). *Absolute risk prediction for cannabis use disorder using Bayesian machine learning* (arXiv Preprint No. arXiv:2501.09156). arXiv.



Lampiran

Source Code

<https://colab.research.google.com/drive/1UHUjnvxYwSIT76Eyhk0C2Hr-fd57ukdC?usp=sharing>

Folder Dokumen Project

<https://drive.google.com/drive/folders/1ywXLeuRGo2KJb54IZwmTyf7eVwA8qOUZ>

Publikasi Github

<https://github.com/AndikaFebrianto018/PROJECT-UAS-DATA-MINING>